



UNIVERSIDADE FEDERAL DO RIO DE JANEIRO

CENTRO DE TECNOLOGIA
ESCOLA POLITÉCNICA

Relatório do Processo ETL e Data Warehouse Integrado

Avaliação 02 — Parte II: Modelagem de DW

Big Data e Data Warehouse

EEL890 / MAE016 — 2026.1

Alunos

Thiago Moutinho de Carvalho Maksoud — DRE 119048139

Thomas Cardoso de Miranda — DRE 122050797

Yan Lukas Willian Tavares — DRE 124341835

Link Github: <https://github.com/thomascard2004/EEL890-big-data>

1. Introdução e Contexto do Negócio

Este relatório descreve o projeto físico e lógico de um **Data Warehouse (DWH) integrado** para um consórcio de seis empresas independentes de aluguel de automóveis. A unificação operacional viabiliza que qualquer veículo alugado seja retirado ou devolvido em qualquer um dos seis pátios compartilhados: Aeroporto do Galeão, Santos Dumont, Rodoviária Novo Rio, Shopping Rio Sul, Nova América e Barra Shopping.

Para suportar análises de dados consolidadas e gerar os quatro relatórios gerenciais globais exigidos, além de modelar uma análise logística preditiva por Cadeia de Markov, o grupo projetou uma arquitetura robusta de **Staging Area** e um modelo dimensional **Esquema Estrela (Star Schema)**, implementados integralmente em **PostgreSQL** (ANSI SQL:1999+).

2. Escolha e Estrutura da Área de Staging

O ecossistema analítico foi dividido logicamente em dois schemas distintos no PostgreSQL:

- **staging** : Zona de transição temporária sem restrições de integridade referencial (FKs), que preserva a estrutura original das fontes transacionais e isola o processamento analítico pesado dos sistemas OLTP operacionais.
- **dw** : Schema onde residem as tabelas dimensionais conformadas e as fatos consolidadas, implementando o modelo estrela finalizado.

As tabelas de transição na staging foram prefixadas com o identificador do grupo de origem para rastreabilidade da linhagem dos dados:

Prefixo	Fonte	SGBD Original
g1_	Nosso OLTP (Thomas, Thiago, Yan)	ANSI SQL
g2_	gupessanha/locadora-dw-parte1	PostgreSQL
g3_	guilherme-hu/EEL890---Big-Data	MySQL
g4_	mhscardoso/bigdata	PostgreSQL

3. Desafios e Regras de Transformação ETL por Grupo

Cada grupo parceiro projetou seu modelo transacional OLTP de maneira distinta. Isso exigiu do pipeline de ETL regras específicas de limpeza, unificação e conformação na fase de **Transformação** (`sql/07_etl_transform.sql`).

3.1. Grupo 1 — Nosso Grupo

- **Conformação de Mecanização:** O campo `mecanizacao` foi padronizado de termos variados como `'AUTO'`, `'AUTOMÁTICO'`, `'AUTOMÁTICA'` para a string uniforme `'AUTOMATICA'`; caso contrário, assume-se `'MANUAL'`.
- **Status de Locações:** Nosso sistema não registrava o status textualmente. Foi criada a coluna calculada `status_conformado`: `'CONCLUIDA'` se a data de devolução real está preenchida, ou `'EM_ANDAMENTO'` se for nula.
- **Cidade de Origem dos Clientes:** O OLTP do G1 não possuía esse dado. Para evitar nulos no DW, o ETL preenche com o valor padrão `'NAO_INFORMADO'`.

3.2. Grupo 2 — gupessanha

- **Desnormalização de Clientes PF/PJ:** No OLTP de origem, clientes Pessoa Física e Jurídica estavam em tabelas separadas com estruturas distintas (CPF × CNPJ). O ETL consolidou ambas em uma única tabela `staging.g2_cliente`, unificando os campos sob o atributo `tipo_pessoa` e aplicando `COALESCE(cpf, cnpj)` para obter o documento unificado.
- **Km Rodados:** O campo de quilometragem foi calculado como `km_chegada - km_saida`.

3.3. Grupo 3 — guilherme-hu

- **Conformação de Tipos de Dados MySQL:** O campo `direcao_auto` (BOOLEAN do MySQL) foi convertido para a dimensão textual: `TRUE → 'AUTOMATICA'`, `FALSE → 'MANUAL'`.
- **Status de Reservas:** A coluna numérica `estado_reserva` (0, 1, 2) foi mapeada para categorias descritivas: `'EM_ANDAMENTO'`, `'CANCELADA'`, `'CONFIRMADA'`.
- **Resolução de Pátio por Vaga:** O G3 não registrava diretamente o pátio de devolução. A transformação resolveu o pátio de entrega executando um lookup via `Devolucao → Vaga → Patio`.

3.4. Grupo 4 — mhscardoso

- **Resolução de Pátio por Vagas:** O G4 registrava apenas o ID da vaga física (`id_vaga_retirada`, `id_vaga_devolvida`). A transformação executou subconsultas na tabela `vaga` para extrair os IDs de pátio correspondentes.
- **Motorista como Cliente:** O G4 utilizava apenas a entidade `motorista`. O ETL mapeou esta tabela como correspondente a cliente (PF) no DW.

- **Classe de Luxo:** A classificação 'A', 'B', 'C' foi mapeada para 'BÁSICO', 'INTERMEDIÁRIO' e 'LUXO'.

4. Estratégia de Carga (Load) e Ordem de Execução

O carregamento das tabelas finais no schema `dw` segue estritamente a integridade referencial, respeitando a dependência entre as entidades:

- Dimensões Independentes** — sem FKs entre si: `dim_tempo`, `dim_empresa`, `dim_patio`, `dim_grupo_veiculo`. A `dim_tempo` é populada previamente com uma série temporal gerada de 2020 a 2030.
- Dimensões Dependentes** — requerem dimensões da etapa anterior: `dim_veiculo` (FK para `dim_grupo_veiculo` e `dim_empresa`) e `dim_cliente`.
- Tabelas de Fatos** — requerem todas as dimensões: `fato_locacao`, `fato_reserva`, `fato_patio_snapshot`. Nas fatos, os IDs naturais das fontes de staging são usados para fazer JOINS com as dimensões (filtrando também pela coluna `fonte_grupo` para garantir isolamento e unicidade de chaves homônimas entre grupos) e obter as **Surrogate Keys (SK)** de cada dimensão.

5. Acionamento das Extrações (Orquestração Temporal)

Para manter o DW atualizado sem impactar a performance transacional das 6 locadoras parceiras, o cronograma de acionamento das rotinas de ETL foi especificado da seguinte forma:

Entidade	Frequência	Horário(s)	Justificativa
Clientes	Diária	02:00	Dados relativamente estáticos
Veículos/Frota	Diária	02:30	Atualizações de manutenção à noite
Locações Fechadas	Diária	03:00	Consolida fechamentos do dia anterior
Reservas	A cada 6h	00:00, 06:00, 12:00, 18:00	Visibilidade ágil da demanda futura
Locações Ativas	A cada 6h	01:00, 07:00, 13:00, 19:00	Monitoramento da frota em trânsito
Pátios e Vagas	Semanal	Dom 03:00	Dados altamente estáticos

6. Análise de Ocupação e Cadeia de Markov

A análise de movimentação da frota foi implementada através de uma modelagem de Cadeias de Markov. O script `sql/10_matriz_markov.sql` calcula a matriz estocástica de probabilidade de transição de um carro sair de um pátio P_i e ser entregue em um pátio P_j .

Desafio Técnico — PostgreSQL e Recursão:

Como o PostgreSQL possui restrições severas contra agregações dentro de recursões (`WITH RECURSIVE`), o grupo contornou a limitação implementando uma multiplicação sucessiva de matrizes por meio do encadeamento de **10 níveis de CTEs de multiplicação**. Isso permitiu obter a convergência da distribuição estacionária ($\pi = \pi \times P$) de maneira limpa, puramente em SQL.

Para fins de validação e demonstração, os scripts SQL foram testados com um conjunto de dados simulado contendo 60 locações com transições distribuídas entre os 6 pátios, obtendo-se os resultados analíticos descritos abaixo.

6.1. Matriz de Transição Estimada (P)

A matriz de probabilidade $P(P_j \mid P_i)$ de um veículo ser devolvido no pátio P_j dado que foi retirado no pátio P_i foi apurada como:

Pátio de Origem (Linha) \ Destino (Coluna)	Galeão	Santos Dumont	Barra Shopping	Nova América	Rio Sul	Rodoviária
Aeroporto Galeão	30.00%	10.00%	40.00%	0.00%	20.00%	0.00%
Aeroporto Santos Dumont	20.00%	40.00%	10.00%	0.00%	30.00%	0.00%
Barra Shopping	20.00%	10.00%	50.00%	10.00%	0.00%	10.00%
Nova América	10.00%	0.00%	10.00%	60.00%	0.00%	20.00%
Rio Sul	20.00%	20.00%	20.00%	0.00%	40.00%	0.00%
Rodoviária Novo Rio	30.00%	10.00%	0.00%	10.00%	0.00%	50.00%

(Nota: a soma de cada linha é exatamente igual a 100%, validando a propriedade estocástica da matriz).

6.2. Vetor Estacionário de Equilíbrio (π)

Partindo de uma distribuição uniforme (16.67% da frota em cada pátio) e multiplicando o vetor de estado sucessivamente pela matriz de transição por 10 iterações de convergência, obteve-se o seguinte vetor estacionário estável de distribuição a longo prazo:

Pátio	Probabilidade Estacionária (π_i)	Ocupação Esperada da Frota
Barra Shopping	0.2867	28.67%
Aeroporto Galeão	0.2222	22.22%
Aeroporto Santos Dumont	0.1505	15.05%

Pátio	Probabilidade Estacionária (π_i)	Ocupação Esperada da Frota
Rio Sul	0.1493	14.93%
Nova América	0.0956	9.56%
Rodoviária Novo Rio	0.0956	9.56%

6.3. Interpretação Logística para Tomada de Decisão

Os resultados revelam uma forte tendência de assimetria na atração de frota:

- Pólo de Atração (Acúmulo):** O **Barra Shopping** é o pátio que tende a reter o maior volume da frota no longo prazo (**28.67%**), seguido pelo **Aeroporto Galeão** (**22.22%**).
- Pólo de Esvaziamento:** Os pátios da **Rodoviária Novo Rio** e do **Nova América** operam no equilíbrio com apenas **9.56%** da frota cada.
- Ação Recomendada (Prescritiva):** A gerência de logística deve programar transferências físicas programadas de veículos do Barra Shopping em direção à Rodoviária Novo Rio e ao Nova América para evitar a falta de carros nessas localidades e o congestionamento físico de vagas na Barra.

7. Conclusão

A implantação do Data Warehouse integrado forneceu uma infraestrutura analítica indispensável para o consórcio de locação de veículos. Antes do DWH, as seis empresas operavam em silos com formatos incompatíveis de tipos de dados, terminologias conflitantes e bases de clientes isoladas.

Com o processo de **staging** e a **conformação de dados** estabelecida nas rotinas de ETL, as empresas agora dispõem de relatórios gerenciais consolidados e precisos sobre: (a) o estado dos pátios por grupo e origem da frota; (b) o volume de locações ativas e seu tempo restante; (c) a demanda futura de reservas por pátio e cidade de origem dos clientes; e (d) os grupos de veículos mais populares cruzados com a origem geográfica dos locatários.

A inteligência adicionada pela **análise de Cadeia de Markov** e pelos relatórios temporais de reservas permite ao consórcio otimizar a distribuição física da frota, reduzir gargalos em pátios de alta rotatividade como os aeroportos e maximizar o faturamento global por meio de uma gestão integrada, baseada em dados históricos centralizados.

Conclui-se que a solução de Data Warehouse atende plenamente os objetivos que nortearam a necessidade da integração analítica: fornecer uma única fonte de verdade consolidada a partir de sistemas heterogêneos, viabilizando tanto os relatórios gerenciais operacionais quanto as análises preditivas de longo prazo para suporte à tomada de decisões estratégicas do consórcio.

